O resultado da mochila entra antes do prompt do RAG

Tokens do prompt

W limita os tokens enviados ao LLM. O top-k da AV1 ignora W e pode estourar: em um caso de teste gasta 11 tokens com W = 4. A mochila 0/1 sempre respeita W.

Latência e custo

A seleção roda antes da geração, sobre M = 200 candidatos. O DP custa Θ(n·W); os gulosos, Θ(n log n). Medido: DP de 13 a 72 ms; gulosos em torno de 0,4 ms.

Risco de evidência

Em um caso de teste, o DP troca o documento mais relevante por três medianos. Um guloso por razão obtém 2,0 onde o ótimo é 10,0. Aproximação não é ótimo.

Este protótipo não gera resposta, então não há verificação de afirmações.

AV2 · FECHAMENTO

Limitações e conclusão

Limitações

- Fonte única: Folha de S.Paulo
- BM25 apenas lexical
- Tokens são um proxy do custo real
- Corte em M = 200 candidatos
- Apenas 3 valores de W (500, 1.000 e 2.000)
- Python em uma única máquina

Conclusão

- A mochila 0/1 por DP é ótima e nunca excede o orçamento W
- Os gulosos são mais rápidos, e só o ratio_plus garante metade do ótimo
- O top-k da AV1 estourou W em 51 de 90 execuções
- Ganho do DP: +1,5% a +2,8% sobre o guloso por razão e até 2x sobre o por score